HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG
KHOA CÔNG NGHỆ THÔNG TIN

BÁO CÁO THỰC TẬP CƠ SỞ

XÂY DỰNG BỘ DỮ LIỆU HARD REASONING CHO CLAIM VERIFICATION

Học phần	: Thực tập cơ sở
Giảng viên hướng dẫn	: TS. Nguyễn Thị Mai Trang
Nhóm học phần	: Nhóm 17
Sinh viên	: Nguyễn Ngọc Phúc - B23DCKH090

Hà Nội - 2026

LỜI MỞ ĐẦU

Trong bối cảnh tin giả lan truyền mạnh mẽ, bài toán Kiểm chứng thông tin tự động (Claim Verification) ngày càng đóng vai trò thiết yếu. Tuy nhiên, quá trình nghiên cứu gặp rào cản lớn do các bộ dữ liệu tiếng Việt hiện tại còn quá đơn giản. Điều này dẫn đến hiện tượng mô hình học máy đạt điểm số rất cao trên tập kiểm thử, nhưng thực chất chỉ đang học vẹt các từ khóa trùng lặp thay vì hiểu được ngữ nghĩa và logic của câu.

Báo cáo này tập trung làm rõ luận điểm: **Hiệu năng cao trên dữ liệu đơn giản không phản ánh đúng năng lực suy luận của mô hình.** Để minh chứng cho điều này, em đã tiến hành xây dựng một bộ dữ liệu *Hard Reasoning* (suy luận khó) nhằm kiểm tra năng lực suy luận thực thụ của các mô hình từ cổ điển đến hiện đại.

1 TỔNG QUAN DỰ ÁN

1.1 Bối cảnh và Đặt vấn đề

Bài toán Claim Verification yêu cầu phân loại một câu phát biểu (Claim) dựa trên bằng chứng (Evidence) thành ba nhãn chính: SUPPORTED (Hỗ trợ), REFUTED (Bác bỏ), hoặc NOT ENOUGH INFO (Không đủ thông tin).

Vấn đề lớn nhất của các mô hình hiện nay là mắc phải **Lexical Overlap Bias** (Thiên kiến trùng lặp từ vựng). Ví dụ cụ thể:

- **Evidence:** *Hà Nội là thủ đô của Việt Nam.*
- **Claim (REFUTED):** *Hà Nội không phải là thủ đô của Việt Nam.*

Trong trường hợp này, hai câu có tỷ lệ trùng lặp từ vựng cực kỳ cao nhưng lại mang ý nghĩa hoàn toàn trái ngược. Các thuật toán truyền thống thường dự đoán sai thành nhãn SUPPORTED do các mô hình này chủ yếu dựa trên tần suất xuất hiện của từ vựng thay vì mô hình hóa quan hệ ngữ nghĩa và cấu trúc logic của câu.

Hiện tượng này cho thấy các hệ thống trí tuệ nhân tạo có thể dễ dàng đạt hiệu năng cao trên các bộ dữ liệu đơn giản mà không thực sự hiểu ngữ nghĩa, dẫn đến việc đánh giá sai năng lực suy luận cốt lõi của hệ thống.

1.2 Mục tiêu của bài tập lớn

Từ những hạn chế và lỗ hổng trong việc đánh giá mô hình nêu trên, bài tập lớn này hướng tới các mục tiêu cụ thể sau:

- **Xây dựng bộ dữ liệu Hard Reasoning:** Tạo ra một tập dữ liệu thử thách chứa các bẫy logic tinh vi nhằm vô hiệu hóa thiên kiến đếm từ vựng.
- **Thiết lập mức cơ sở (Baseline):** Đánh giá hiệu năng của các thuật toán máy học truyền thống (TF-IDF kết hợp Logistic Regression/SVM) khi đối mặt với bẫy ngữ nghĩa.
- **Tinh chỉnh mô hình ngôn ngữ lớn:** Fine-tune mô hình PhoBERT để kiểm chứng khả năng xử lý bối cảnh sâu của kiến trúc Transformer.
- **So sánh và đối chiếu có chủ đích:** Phân tích sự chênh lệch hiệu năng của các mô hình khi chuyển đổi từ tập dữ liệu dễ sang tập dữ liệu khó, qua đó làm rõ sự khác biệt giữa hiệu năng bề mặt (surface performance) và năng lực suy luận thực sự (true reasoning capability) của Trí tuệ nhân tạo.

2 CƠ SỞ LÝ THUYẾT VÀ HẠN CHẾ CỦA MÔ HÌNH

2.1 Phương pháp trích xuất đặc trưng TF-IDF

TF-IDF biểu diễn văn bản dưới dạng vector trọng số, được tính bằng tích của tần suất xuất hiện của từ (TF) và nghịch đảo tần suất văn bản chứa từ đó (IDF):

$$TFIDF = TF \times IDF \tag{1}$$

Hạn chế cốt lõi: Do hoạt động theo mô hình "túi từ"(Bag-of-words), TF-IDF hoàn toàn không nắm bắt được quan hệ ngữ nghĩa, trật tự từ và cấu trúc logic của câu. Điều này khiến phương pháp này đặc biệt dễ bị đánh lừa trong các trường hợp có sự trùng lặp từ vựng cao nhưng ý nghĩa bị đảo ngược, như trong các bài toán Claim Verification.

2.2 Các thuật toán phân loại máy học

Logistic Regression dự đoán xác suất thuộc về một lớp thông qua hàm Sigmoid:

$$P(y = 1|x) = \frac{1}{1 + e^{-(w^T x + b)}} \tag{2}$$

Support Vector Machine (SVM) tìm kiếm siêu phẳng phân tách tối ưu:

$$\min_{w,b} \frac{1}{2}||w||^2 + C \sum_{i=1}^{n} \max(0, 1 - y_i(w^T x_i + b)) \tag{3}$$

Mặc dù có nền tảng toán học vững chắc, các mô hình này phụ thuộc hoàn toàn vào chất lượng của đặc trưng đầu vào. Do sử dụng TF-IDF làm biểu diễn, Logistic Regression và SVM thừa hưởng trực tiếp các hạn chế về mặt ngữ nghĩa, khiến chúng sụp đổ trước các bẫy đảo logic phức tạp.

2.3 Mô hình Học sâu và Cơ chế Attention

Kiến trúc Transformer khắc phục điểm yếu của máy học truyền thống thông qua cơ chế Self-Attention, cho phép mô hình tính toán mức độ quan trọng của các từ xung quanh đối với một từ cụ thể:

$$Attention(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right) V \tag{4}$$

Mặc dù có khả năng nắm bắt ngữ cảnh tốt hơn nhờ cơ chế Attention (như trong mô hình PhoBERT), hiệu năng của các mô hình học sâu vẫn phụ thuộc mạnh vào đặc điểm của dữ liệu huấn luyện. Hiệu năng này hoàn toàn có thể suy giảm mạnh khi mô hình đối mặt với các trường hợp "hiếm"yêu cầu khả năng suy luận logic ngầm mà chưa từng xuất hiện trong tập huấn luyện.

2.4 Tiêu chí đánh giá

Bài tập lớn sử dụng độ chính xác tổng thể (Accuracy) để đo lường tỷ lệ dự đoán đúng:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \tag{5}$$

Tuy nhiên, bên cạnh Accuracy, chỉ số **Macro-F1** được sử dụng làm thước đo song song. Macro-F1 đặc biệt quan trọng trong bối cảnh bài toán phân loại đa nhãn (Multi-class Classification), giúp tránh

trường hợp mô hình đạt Accuracy cao nhờ thiên vị nhãn đa số (Majority class) nhưng lại dự đoán sai hoàn toàn các lớp thiểu số.

3 PHƯƠNG PHÁP XÂY DỰNG DỮ LIỆU

3.1 Tiền xử lý văn bản

Áp dụng thư viện `underthesea` để thực hiện tách từ (Word Segmentation) theo chuẩn tiếng Việt, giúp duy trì cấu trúc của các từ ghép trước khi đưa vào mô hình hóa.

3.2 Tập dữ liệu Cơ bản (Baseline Dataset)

Bộ dữ liệu ban đầu gồm 1000 mẫu. Điểm đặc trưng của tập này là câu Claim thường được trích xuất trực tiếp hoặc có rất ít sự thay đổi so với Evidence. Mức độ Lexical Overlap duy trì ở mức cao (80% - 90%). Điều này khiến bài toán trở nên tương đối dễ, khi mô hình có thể dự đoán dựa trên sự trùng lặp từ khóa mà không cần suy luận sâu.

3.3 Tập dữ liệu Hard Reasoning

Mục tiêu của việc thiết kế tập dữ liệu này là loại bỏ khả năng "học vẹt"dựa trên từ khóa, buộc mô hình phải thực hiện suy luận ngữ nghĩa thực sự.

Để tạo ra thử thách này, dữ liệu được can thiệp thủ công theo ba hướng chính. Điểm cốt lõi là *duy trì độ trùng lặp từ vựng cao (>70%) nhưng thay đổi hoàn toàn logic câu*:

- **Bẫy Paraphrase:** Viết lại câu bằng từ đồng nghĩa hoặc đổi cấu trúc ngữ pháp nhưng giữ nguyên ý (ép nhãn SUPPORTED). Điều này buộc mô hình phải dựa vào hiểu biết ngữ nghĩa thay vì so khớp từ khóa.
- **Bẫy Đảo logic:** Giữ nguyên hầu hết từ vựng nhưng hoán đổi vị trí chủ - vị hoặc đảo ngược quan hệ nhân quả (ép nhãn REFUTED).
- **Suy luận ngầm:** Yêu cầu mô hình có kiến thức nền tảng về toán học hoặc định vị không gian, thời gian. Ví dụ: suy luận về thứ tự thời gian, quan hệ vị trí (trước/sau, trên/dưới) hoặc các phép toán đơn giản (như cộng trừ số liệu, tỷ lệ phần trăm).

3.4 So sánh minh chứng giữa dữ liệu cơ bản và Hard Reasoning

Để làm rõ sự khác biệt về độ khó, nhóm tiến hành đối chiếu các mẫu dữ liệu thực tế sau khi đã áp dụng kỹ thuật gài bẫy logic. Bảng dưới đây trình bày sự thay đổi của Claim đối với cùng một đoạn văn bằng chứng (Evidence):

Phân tích mẫu vi_0002: Trong tập dữ liệu cơ bản, Claim mang tính khẳng định tuyệt đối ("vĩnh viễn"), rất dễ bị bác bỏ. Ở tập Hard Reasoning, thông tin được thay đổi tinh vi thành "vài thập kỷ"(đối lập với "một thiên niên kỷ"trong Evidence). Kỹ thuật này giữ cho tỷ lệ trùng lặp từ vựng rất cao nhưng làm thay đổi hoàn toàn giá trị chân lý, buộc mô hình phải có khả năng hiểu định lượng thay vì chỉ so khớp từ khóa.

ID	Claim nguyên bản (Dễ)	Claim Hard Reasoning (Khó)	Nhãn
vi_0001	Cuộc khởi nghĩa Lam Sơn thành công đánh bại quân Minh đã chính thức khép lại giai đoạn...	Mốc xuất phát của lịch sử dân tộc gắn liền với hai triều đại Âu Lạc và Văn Lang.	SUPPORTED
vi_0002	Thắng lợi vang dội của Ngô Quyền trước quân Nam Hán đã chấm dứt vĩnh viễn mọi cuộc chiến tranh xâm lược...	Giai đoạn chịu sự cai trị của phong kiến phương Bắc chỉ tồn tại trong vòng vài thập kỷ.	REFUTED
vi_0003	Sự kiện nhà Triệu thôn tính Âu Lạc... dẫn đến việc hàng chục vạn người dân Âu Lạc phải di tản...	Chiến thắng trước nhà Minh của nghĩa quân Lam Sơn đạt được nhờ sử dụng vũ khí từ phương Tây.	NEI

Bảng 1: Đối chiếu nội dung Claim giữa hai bộ dữ liệu.

4 KẾT QUẢ THỰC NGHIỆM VÀ PHÂN TÍCH

4.1 Cài đặt thực nghiệm và Triển khai mã nguồn

Để thực hiện các thực nghiệm so sánh, nhóm đã triển khai hệ thống trên ngôn ngữ Python với các thư viện lõi như `scikit-learn` cho các mô hình truyền thống và `transformers` (Hugging Face) cho mô hình ngôn ngữ lớn PhoBERT. Dữ liệu được quản lý và xử lý thông qua thư viện `pandas`.

4.1.1 Xây dựng Pipeline cho mô hình truyền thống (TF-IDF)

Trong phương pháp này, nhóm sử dụng `underthesea` để tách từ tiếng Việt. Đặc biệt, câu Claim và Evidence được kết hợp với nhau thông qua ký tự phân tách đặc biệt `[SEP]` để mô hình có thể nhận diện ranh giới ngữ cảnh.

```python
# 1. Tien xu ly va chuan hoa nhan (Label Mapping)
label_map = {"SUPPORTED": "SUPPORTED", "REFUTED": "REFUTED", "NEI": "NEI"}
df_all['Label'] = df_all['Label'].astype(str).str.strip().str.upper().map(label_map)

# 2. Ham tach tu Tieng Viet (Word Segmentation)
def preprocess(claim, evidence):
    c_tok = word_tokenize(str(claim), format="text")
    e_tok = word_tokenize(str(evidence)[:300], format="text")
    return c_tok + " [SEP] " + e_tok

X = df_all.apply(lambda row: preprocess(row['Claim'], row['Evidence']), axis=1)

# 3. Trich xuat dac trung TF-IDF (Unigram + Bigram)
vectorizer = TfidfVectorizer(max_features=2000, ngram_range=(1, 2))
X_train_tfidf = vectorizer.fit_transform(X_train)

# 4. Huan luyen mo hinh voi trong so lop can bang (Balanced Class Weight)
lr_model = LogisticRegression(max_iter=1000, class_weight='balanced', random_state=42)
lr_model.fit(X_train_tfidf, y_train)

svm_model = SVC(kernel='linear', class_weight='balanced', random_state=42)
svm_model.fit(X_train_tfidf, y_train)
```

Listing 1: Tien xu ly va huan luyen mo hinh Machine Learning truyen thong

4.1.2 Cấu hình mô hình Deep Learning (PhoBERT)

Đối với PhoBERT, nhóm sử dụng phiên bản `vinai/phobert-base-v2`. Claim và Evidence được nối bằng ký tự đặc biệt của RoBERTa (`</s></s>`).

```python
# 1. Khoi tao Tokenizer va Dataset cho HuggingFace
tokenizer = AutoTokenizer.from_pretrained("vinai/phobert-base-v2")
train_data = Dataset.from_pandas(train_df[['text', 'Label']].rename(columns={"Label": "
    labels"}))

def tokenize_function(examples):
    return tokenizer(examples["text"], padding=True, truncation=True, max_length=256)

train_tokenized = train_data.map(tokenize_function, batched=True)

# 2. Cau hinh huan luyen (Training Arguments)
training_args = TrainingArguments(
    output_dir="./results",
    num_train_epochs=5,
    learning_rate=2e-5,
    per_device_train_batch_size=8,
    weight_decay=0.01,
    do_eval=True,
    logging_steps=10
)

# 3. Khoi tao Trainer va bat dau Fine-tuning
trainer = Trainer(
    model=AutoModelForSequenceClassification.from_pretrained("vinai/phobert-base-v2",
    num_labels=3),
    args=training_args,
    train_dataset=train_tokenized,
    eval_dataset=dev_tokenized,
    compute_metrics=compute_metrics
)
trainer.train()
```

Listing 2: Trien khai mo hinh Deep Learning PhoBERT

4.2 Giai đoạn 1: Thực nghiệm trên dữ liệu Cơ bản

Khi huấn luyện và kiểm thử trên bộ dữ liệu 1000 câu đơn giản:

- Mô hình truyền thống (TF-IDF + Logistic Regression/SVM) đạt Accuracy khoảng **60%**, với Macro-F1 đạt mức tương đương.

```
evaluate_model("TF-IDF + SVM", y_test, y_pred_svm)

Tổng số mẫu: 3999
Train: 2799 | Dev: 600 | Test: 600

=== KẾT QUẢ: TF-IDF + Logistic Regression ===
Accuracy : 0.545
Macro-F1 : 0.5447440739683588
Confusion Matrix:
 [[ 95  39  65]
 [ 29 127  45]
 [ 61  34 105]]
----------------------------------------
=== KẾT QUẢ: TF-IDF + SVM ===
Accuracy : 0.53
Macro-F1 : 0.5308084772370486
Confusion Matrix:
 [[ 94  38  67]
 [ 32 122  47]
 [ 67  31 102]]
----------------------------------------
```

Hình 1: Kết quả thực nghiệm của mô hình TF-IDF trên dữ liệu Cơ bản

- Mô hình PhoBERT đạt Accuracy vượt trội lên tới **94.26%**.

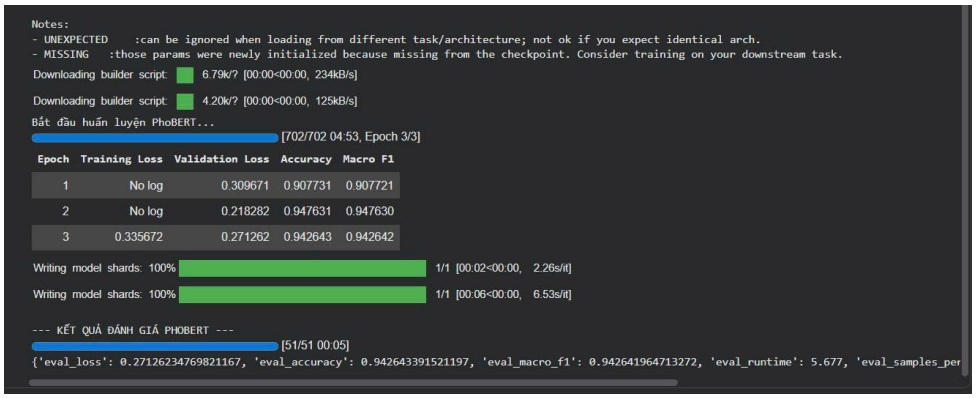

Hình 2: Kết quả thực nghiệm của mô hình PhoBERT trên dữ liệu Cơ bản

Nhận xét: Kết quả này minh chứng cho hiện tượng *shortcut learning* (học đường tắt). Mô hình có thể đạt điểm cao bằng cách khai thác các tín hiệu bề mặt (surface patterns) và sự trùng lặp từ vựng thay vì học được quan hệ suy luận thực sự giữa Claim và Evidence

4.3 Giai đoạn 2: Thực nghiệm trên dữ liệu Hard Reasoning

Trái ngược với Giai đoạn 1, khi đối mặt với bộ dữ liệu Hard Reasoning đã được gài bẫy logic, hiệu năng của cả hai phương tiếp cận đều có sự sụt giảm nghiêm trọng:

- **Mô hình truyền thống (TF-IDF):** Accuracy lao dốc mạnh mẽ, chỉ còn **13.51%**, thấp hơn cả xác suất dự đoán ngẫu nhiên (33.3%). Điều này cho thấy sự sụp đổ hoàn toàn của phương pháp thống kê từ vựng khi cấu trúc logic bị thay đổi tinh vi.
- **Mô hình học sâu (PhoBERT):** Hiệu năng cũng có sự sụt giảm đáng kể (Accuracy giảm xuống còn **76**%). Mặc dù vẫn cao hơn TF-IDF nhờ khả năng hiểu ngữ cảnh, nhưng con số này cho thấy ngay cả các kiến trúc Transformer tiên tiến cũng gặp thách thức lớn khi đối mặt với bẫy Lexical Overlap.

Phân tích nguyên nhân: Sự sụt giảm đồng loạt này khẳng định sự tồn tại của *Lexical Overlap Bias*. Các mẫu thuộc nhãn REFUTED gần như bị phân loại sai hoàn toàn thành SUPPORTED do sự trùng lặp từ vựng quá cao. Điều này chứng minh rằng việc đánh giá chỉ dựa trên Accuracy ở các tập dữ liệu dễ sẽ dẫn đến cái nhìn sai lệch về năng lực thực sự của hệ thống.

Kết luận trung gian: Khoảng cách hiệu năng giữa tập dữ liệu cơ bản và tập Hard Reasoning cho thấy các mô hình hiện tại vẫn chưa có khả năng tổng quát hóa (generalization) tốt khi cấu trúc logic bị thay đổi. Kết quả thực nghiệm này hoàn toàn khớp với giả thuyết thiết kế dữ liệu đã đặt ra.

5 TỔNG KẾT VÀ HƯỚNG PHÁT TRIỂN

5.1 Kết luận

Báo cáo đã chỉ ra một cách hệ thống những hạn chế của các mô hình học máy truyền thống khi đối mặt với các bài toán yêu cầu suy luận logic. Sự suy giảm hiệu năng nghiêm trọng từ khoảng **60%** xuống chỉ còn **13.51%** trên tập dữ liệu Hard Reasoning là bằng chứng định lượng rõ ràng cho nhận định này.

Bộ dữ liệu Hard Reasoning được xây dựng trong dự án đã chứng minh được vai trò như một bài *stress-test* hiệu quả, giúp bộc lộ sự phụ thuộc nặng nề của các mô hình thống kê vào các tín hiệu từ vựng bề mặt (surface lexical signals). Kết quả thực nghiệm đồng thời cho thấy sự cần thiết của các mô hình

```
Đang tách từ (Word Segmentation) - Vui lòng đợi vài giây...
Tổng số mẫu: 366
Train: 292 | Dev: 37 | Test: 37

=== KẾT QUẢ: TF-IDF + Logistic Regression (Tập Test) ===
Phân phối dự đoán (Counter): {'SUPPORTED': 16, 'NEI': 10, 'REFUTED': 11}
Accuracy : 0.1351
Macro-F1 : 0.1242
Chi tiết:
              precision    recall  f1-score   support

         NEI       0.10      0.08      0.09        13
     REFUTED       0.00      0.00      0.00        12
   SUPPORTED       0.25      0.33      0.29        12

    accuracy                           0.14        37
   macro avg       0.12      0.14      0.12        37
weighted avg       0.12      0.14      0.12        37

--------------------------------------------------
```

```
--------------------------------------------------
=== KẾT QUẢ: TF-IDF + SVM (Tập Test) ===
Phân phối dự đoán (Counter): {'SUPPORTED': 16, 'NEI': 11, 'REFUTED': 10}
Accuracy : 0.1351
Macro-F1 : 0.1230
Chi tiết:
              precision    recall  f1-score   support

         NEI       0.09      0.08      0.08        13
     REFUTED       0.00      0.00      0.00        12
   SUPPORTED       0.25      0.33      0.29        12

    accuracy                           0.14        37
   macro avg       0.11      0.14      0.12        37
weighted avg       0.11      0.14      0.12        37

--------------------------------------------------
```

```
180        0.478202

Writing model shards: 100%  1/1 [00:07<00:00,  7.09s/it]

--- TEST ---
{'eval_loss': 0.6755850315093994, 'eval_accuracy': 0.7567567567567568, 'eval_macro_f1': 0.7595986622073578, 'eval_runtime': 0

--- REPORT ---
              precision    recall  f1-score   support

SUPPORTED (0)       1.00      0.77      0.87        13
  REFUTED (1)       0.71      0.83      0.77        12
      NEI (2)       0.62      0.67      0.64        12

    accuracy                           0.76        37
   macro avg       0.78      0.76      0.76        37
weighted avg       0.78      0.76      0.76        37
```

Hình 3: Kết quả thực nghiệm chi tiết trên tập dữ liệu Hard Reasoning.

có khả năng nắm bắt ngữ nghĩa sâu, như các kiến trúc Transformer (PhoBERT), trong bài toán xác thực thông tin tiếng Việt.

5.2 Hướng phát triển trong tương lai

Dựa trên những kết quả đã đạt được, nhóm đề xuất các hướng phát triển tiếp theo nhằm tối ưu hóa hệ thống:

- **Mở rộng quy mô dữ liệu:** Tiếp tục gia tăng số lượng mẫu Hard Reasoning nhằm phục vụ việc tinh chỉnh (fine-tuning) hiệu quả các mô hình ngôn ngữ lớn (LLM) có quy mô tham số rộng hơn.
- **Xây dựng hệ thống End-to-End:** Tích hợp kiến trúc Retrieval-Augmented Generation (RAG) để xây dựng một quy trình xác thực thông tin hoàn chỉnh, từ khâu truy xuất bằng chứng tự động đến khâu đưa ra kết luận cuối cùng.
- **Nghiên cứu Trí tuệ nhân tạo có khả năng giải thích (XAI):** Phát triển các cơ chế giải thích quy trình suy luận của mô hình nhằm nâng cao tính minh bạch, độ tin cậy và giúp người dùng hiểu

rõ căn cứ của các quyết định xác thực.